

به نام خدا



دانشگاه تهران  
پردیس دانشکده‌های فنی  
دانشکده برق و کامپیوتر



## درس سیستم‌های هوشمند

### تمرین شماره ۱

نام و نام خانوادگی : سیاوش شمس

شماره دانشجویی : ۸۱۰۱۹۷۶۴۴

آبان ۱۴۰۰

## فهرست سوالات

سوال ۱..... ۳

الف:..... ۳

ب:..... ۳

ج:..... ۵

د:..... ۶

سوال ۲..... ۷

الف:..... ۷

ب:..... ۹

ج:..... ۱۱

سوال ۳..... ۱۳

الف:..... ۱۳

ب:..... ۱۴

## سوال ۱

برای محاسبه نقاط کمینه بخش الف ابتدا گرادیان تابع داده شده را حساب میکنیم و سپس با به دست آوردن هسین نوع آن را تعیین میکنیم. در بخش ب دو تکرار روش گرادیان نزولی را به صورت دستی انجام دادیم و سپس این روش را به کمک متلب پیاده سازی کردیم و نتایج را وارد کردیم، در قسمت ج هم روش نیوتن را بررسی میکنیم. در قسمت د فرم ماتریسی قسمت الف را محاسبه کرده و با فرم ماتریسی این بخش مقایسه میکنیم.

الف:

$$\nabla f = \begin{bmatrix} 6x_1 + 6x_2 + 12 \\ 16x_2 + 6x_1 + 8 \end{bmatrix}$$

$$\nabla f = 0 \rightarrow x_1 = \frac{-12}{5}, x_2 = \frac{2}{5}$$

$$H(x_1, x_2) = \begin{bmatrix} 6 & 6 \\ 6 & 16 \end{bmatrix}$$

$$\det(H - \lambda I) = 0 \rightarrow \begin{vmatrix} 6 - \lambda & 6 \\ 6 & 16 - \lambda \end{vmatrix} = \lambda^2 - 22\lambda + 60 = 0 \rightarrow \lambda_1 = 11 - \sqrt{61}, \\ \lambda_2 = 11 + \sqrt{61}$$

هر دو مقادیر ویژه پیدا شده برای تابع  $H$  مثبت هستند پس این تابع مثبت معین<sup>۱</sup> است. در نتیجه نقطه پیدا شده مینیمم محلی است و چون  $H$  همیشه به ازای همه  $x$  ها مثبت معین است این نقطه مینیمم سراسری<sup>۲</sup> است.

ب:

$$p = -\nabla f|_{x=(1,1)} = \begin{bmatrix} -24 \\ -30 \end{bmatrix}$$

$$\varphi(\alpha) = f(x^k + \alpha p^k) = 13248\alpha^2 - 1476\alpha + 37$$

$$\frac{d\varphi}{d\alpha} = 26496\alpha - 1476 = 0 \rightarrow \alpha = 0.056$$

تکرار اول:

$$x^2 = x^1 + \alpha^1 p^1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} + 0.056 \begin{bmatrix} -24 \\ -30 \end{bmatrix} = \begin{bmatrix} -0.344 \\ -0.68 \end{bmatrix}$$

<sup>1</sup> Positive-definite

<sup>2</sup> Global

تکرار دوم:

$$p = -\nabla f|_{x=(-0.344, -0.68)} = \begin{bmatrix} -5.86 \\ 4.944 \end{bmatrix}$$

$$\varphi(\alpha) = f(x^k + \alpha p^k) = 124.73\alpha^2 - 58.76\alpha - 4.11$$

$$\frac{d\varphi}{d\alpha} = 249.46\alpha - 58.76 = 0 \rightarrow \alpha = 0.235$$

$$x^3 = x^2 + \alpha^2 p^2 = \begin{bmatrix} -0.344 \\ -0.68 \end{bmatrix} + 0.235 \begin{bmatrix} -5.86 \\ 4.944 \end{bmatrix} = \begin{bmatrix} -1.72 \\ 0.48 \end{bmatrix}$$

1.0000	1.0000
-0.3370	-0.6712
-1.8068	0.5047
-2.0401	0.2131
-2.2965	0.4183
-2.3372	0.3674
-2.3819	0.4032
-2.3890	0.3943
-2.3968	0.4006
-2.3981	0.3990
-2.3995	0.4001
-2.3997	0.3998
-2.3999	0.4000
-2.3999	0.4000
-2.4000	0.4000

شکل ۱-۱ - روند تغییرات x در روش Gradient Descent به کمک MATLAB

0
0.0557
0.2470
0.0557
0.2470
0.0557
0.2470
0.0557
0.2470
0.0557
0.2470
0.0557
0.2470
0.0557
0.2470

شکل ۱-۲ - روند تغییرات طول گام در روش Line Search به کمک MATLAB

می‌بینیم که نتایج به دست آمده از شبیه سازی به کمک MATLAB با تکرار های دستی تقریباً یکسان است. و نتیجه نهایی نیز طبق انتظار به دست آمد.

ج:

$$p = -(\nabla^2 f|_{x=(1,1)})^{-1} \cdot \nabla f|_{x=(1,1)} = \begin{bmatrix} -3.4 \\ -0.6 \end{bmatrix}$$

$$x^2 = x^1 - p = \begin{bmatrix} -2.4 \\ 0.4 \end{bmatrix}$$

$$p = -(\nabla^2 f|_{x=(-2.4,0.4)})^{-1} \cdot \nabla f|_{x=(-2.4,0.4)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$x^3 = x^2 - p = \begin{bmatrix} -2.4 \\ 0.4 \end{bmatrix}$$

بله روش نیوتن برای این سوال کاربرد دارد، همانطور که می‌بینیم مقادیر بردار  $x$  با اولین تکرار به مقادیر بهینه رسیدند، زیرا این تابع دارای گرادیان و هسین پیوسته است همچنین حدس اولیه دور از نقطه بهینه نیست.

د:

$$\nabla f = \frac{1}{2}(A + A^T)x + \begin{bmatrix} 12 \\ 8 \end{bmatrix} = \begin{bmatrix} 6x_1 + 6x_2 + 12 \\ 16x_2 + 6x_1 + 8 \end{bmatrix}$$

$$\nabla^2 f = \frac{1}{2}(A + A^T) = \begin{bmatrix} 6 & 6 \\ 6 & 16 \end{bmatrix}$$

$$\nabla f = 0 \rightarrow x_1 = \frac{-12}{5}, x_2 = \frac{2}{5}$$

فرم ماتریسی الف:

$$f(x_1, x_2) = \frac{1}{2}x^T \begin{bmatrix} 6 & a \\ b & 16 \end{bmatrix} x + \begin{bmatrix} 12 \\ 8 \end{bmatrix}^T x, \quad a + b = 12$$

از فرم ماتریسی قسمت الف می فهمیم که دو درایه  $a, b$  دو درایه کم اهمیت هستند و با انتخاب دلخواه آنها به شرطی که  $a + b = 12$  شود، گرادیان و هسین تابع یکی هستند و در نتیجه نقاط کمینه یکسان هستند.

## سوال ۲

در بخش اول با روش گردایان نزولی با گام ثابت با نقطه اولیه رفتار تابع را بررسی کردیم، در بخش ب دو روش تحلیلی و آرمیجو را برای تابع بررسی کردیم و از نظر سرعت همگرایی آنها را مقایسه کردیم، سپس در قسمت ج به کمک روش فراابتکاری تبرید شبیه سازی<sup>۱</sup> مقدار بهینه تابع را پیدا کردیم

الف:

با نقطه اولیه (5,5) و گام ثابت 0.01 شروع کردیم و در تکرار ۳۵ ام به مقدار کمینه محلی رسیدیم.

1	25	23	-71.1361	1	5	5	24	9.2496	4.9944
2	23.1486	24	-72.7363	2	5.0500	4.8000	25	9.3572	4.9959
3	22.7573	25	-73.7789	3	5.1038	4.8408	26	9.4434	4.9970
4	22.3027	26	-74.4472	4	5.1685	4.8354	27	9.5121	4.9977
5	21.6818	27	-74.8708	5	5.2440	4.8393	28	9.5666	4.9982
6	20.8310	28	-75.1371	6	5.3326	4.8419	29	9.6097	4.9986
7	19.6682	29	-75.3036	7	5.4361	4.8456	30	9.6438	4.9988
8	18.0854	30	-75.4072	8	5.5569	4.8500	31	9.6706	4.9990
9	15.9450	31	-75.4716	9	5.6976	4.8553	32	9.6918	4.9992
10	13.0781	32	-75.5115	10	5.8606	4.8618	33	9.7084	4.9992
11	9.2922	33	-75.5361	11	6.0484	4.8697	34	9.7214	4.9993
12	4.3916	34	-75.5514	12	6.2627	4.8791	35	9.7317	4.9994
13	-1.7791	35	-75.5608	13	6.5043	4.8900			
14	-9.2673			14	6.7718	4.9025			
15	-17.9305			15	7.0616	4.9163			
16	-27.3792			16	7.3668	4.9306			
17	-36.9962			17	7.6776	4.9446			
18	-46.0675			18	7.9824	4.9575			
19	-53.9809			19	8.2698	4.9685			
20	-60.3891			20	8.5307	4.9773			
21	-65.2475			21	8.7594	4.9839			
22	-68.7358			22	8.9543	4.9887			
23	-71.1361			23	9.1167	4.9921			

شکل ۱-۲ - روند تغییرات بردار x در جدول راست و مقدار تابع در جدول چپ

<sup>1</sup> Simulated Annealing

با نقطه اولیه (5,-5) و گام ثابت 0.01 شروع کردیم و در تکرار ۳۴ ام به مقدار کمینه محلی رسیدیم.

1	75	24	-69.3717	1	-5	-5	24	-5.1219	-2.5407
2	69.4281	25	-69.4878	2	-4.7500	-5	25	-5.1571	-2.5402
3	66.0010	26	-69.5778	3	-4.5541	-4.9988	26	-5.1880	-2.5398
4	63.8634	27	-69.6476	4	-4.3999	-4.9936	27	-5.2153	-2.5394
5	62.4827	28	-69.7018	5	-4.2774	-4.9800	28	-5.2393	-2.5390
6	61.4700	29	-69.7439	6	-4.1792	-4.9499	29	-5.2604	-2.5387
7	60.3238	30	-69.7765	7	-4.0993	-4.8884	30	-5.2790	-2.5384
8	57.7750	31	-69.8019	8	-4.0334	-4.7671	31	-5.2955	-2.5381
9	49.8269	32	-69.8217	9	-3.9801	-4.5344	32	-5.3099	-2.5378
10	25.8992	33	-69.8370	10	-3.9458	-4.1096	33	-5.3227	-2.5376
11	-22.5493			11	-3.9601	-3.4372	34	-5.3340	-2.5374
12	-56.6899			12	-4.0697	-2.7583			
13	-61.4549			13	-4.2261	-2.5419			
14	-63.3045			14	-4.3660	-2.5375			
15	-64.7642			15	-4.4904	-2.5402			
16	-65.9093			16	-4.6006	-2.5416			
17	-66.8029			17	-4.6980	-2.5423			
18	-67.4978			18	-4.7840	-2.5426			
19	-68.0369			19	-4.8597	-2.5426			
20	-68.4545			20	-4.9264	-2.5423			
21	-68.7778			21	-4.9850	-2.5420			
22	-69.0280			22	-5.0366	-2.5416			
23	-69.2217			23	-5.0820	-2.5411			
				24	-5.1219	-2.5407			

شکل ۲-۲ - روند تغییرات بردار  $x$  در جدول راست و مقدار تابع در جدول چپ

تا وقتی که طول گام به اندازه ای نباشد تا باعث شود از روی مینیمم محلی پرش داشته باشیم می توان آن را انتخاب کرد، در غیر اینصورت این کار منجر به واگرا شدن الگوریتم می شود، در این مورد با انجام آزمایش طول گام باید کمتر از 0.11 باشد تا الگوریتم همگرا شود. همچنین مقدار دقیق طول گام را میتوان با استفاده از قانون پیوستگی گرادیان لپشیتس<sup>۱</sup> به دست آورد.

<sup>1</sup> Lipschitz Continuous Gradient



پ:

1	0	0
2	1.0207	0.6804
3	0.5724	1.3528
4	0.3215	1.1855
5	0.3860	1.0888

1	0
2	-13.9936
3	-9.3986
4	-10.4956
5	-10.3997

شکل ۳-۲ - روند تغییرات بردار  $x$  در جدول چپ و مقدار تابع در جدول راست با روش تحلیلی برای به دست آوردن طول گام

1	0
2	0.0680
3	-0.0855
4	0.0413
5	-0.0699

شکل ۴-۲ - روند تغییرات طول گام با روش تحلیلی

1	0	0	1	-11.0859
2	0.6000	0.4000	2	-15.1591
3	1.0408	0.5220	3	-23.6226
4	1.7744	0.0456	4	-31.4949
5	3.2231	0.3565	5	-38.5656
6	3.3018	-0.1319	6	-40.3850
7	3.5268	0.0121	7	-41.8559
8	3.7834	-0.2172	8	-43.4759
9	3.8899	-0.0478	9	-45.4165
10	4.2604	-0.2067	10	-46.1344
11	4.3948	0.0413	11	-47.1688
12	4.4339	-0.0464	12	-47.8300
13	4.6554	-0.2037	13	-48.7435
14	4.6924	-0.1167	14	-49.3453

شکل ۵-۲ - روند تغییرات بردار  $x$  در جدول چپ و مقدار تابع در جدول راست با روش آرمیجو برای به دست آوردن طول گام

1	0.0400
2	0.0400
3	0.0939
4	0.1297
5	0.0155
6	0.0252
7	0.0325
8	0.0136
9	0.0502
10	0.0205
11	0.0064
12	0.0357
13	0.0068
14	0.0430

شکل ۶-۲ - روند تغییرات طول گام با روش آرمیجو<sup>۱</sup>

1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18
18.0278	11.4335	9.3130	11.4240	31.8248	10.5858	10.5751	14.6987	8.0366	13.7616	14.9589	7.6158	13.9807	6.5194	14.1705	6.3032	16.3837	16.0
43	44	45	46	47	48	49	50	51	52	53	54	55	56	57	58	59	60
3.3561	1.6465	1.6339	5.2610	1.8266	1.5353	1.9498	2.1954	1.3312	1.8910	2.8403	1.9922	1.2120	1.7104	2.6161	1.8680	1.0644	1.3490

error function with  
backtracking line search

1	2	3	4
18.0278	9.4531	7.2932	1.6645

error function with exact  
line search method

شکل ۷-۲ - مقایسه تابع خطای دو روش شبیه سازی شده

با مقایسه تابع خطای دو روش و رابطه زیر میبینیم نرخ همگرایی در روش تحلیلی به دست آوردن طول گام در این مسئله بهتر است و سریعتر به جواب می رسد، اما با مقایسه طول گام در دو روش متوجه می شویم روش آرمیجو پایداری بیشتری دارد و احتمال واگرایی کمتر است.

$$\frac{e(x_{k+1})}{e(x_k)}$$

توضیحات روش آرمیجو: در این روش از مقدار  $c = 0.01$  و  $\beta = 0.2$  استفاده کردیم، و برای محاسبه طول گام اولیه بعد از تکرار دوم از رابطه زیر استفاده کردیم.

<sup>1</sup> Armijo

$$\alpha^0 = \frac{2(f_k - f_{k-1})}{\nabla f_k^T p_k}$$

این روش در نهایت با ۶۰ گام به مقدار کمینه محلی -56 در نقطه (6.95,-0.015) همگرا شد.

ج:

```
Mimumum found for the function equals -75.543108
Vector that results in minimum is 9.732527 5.011950
```

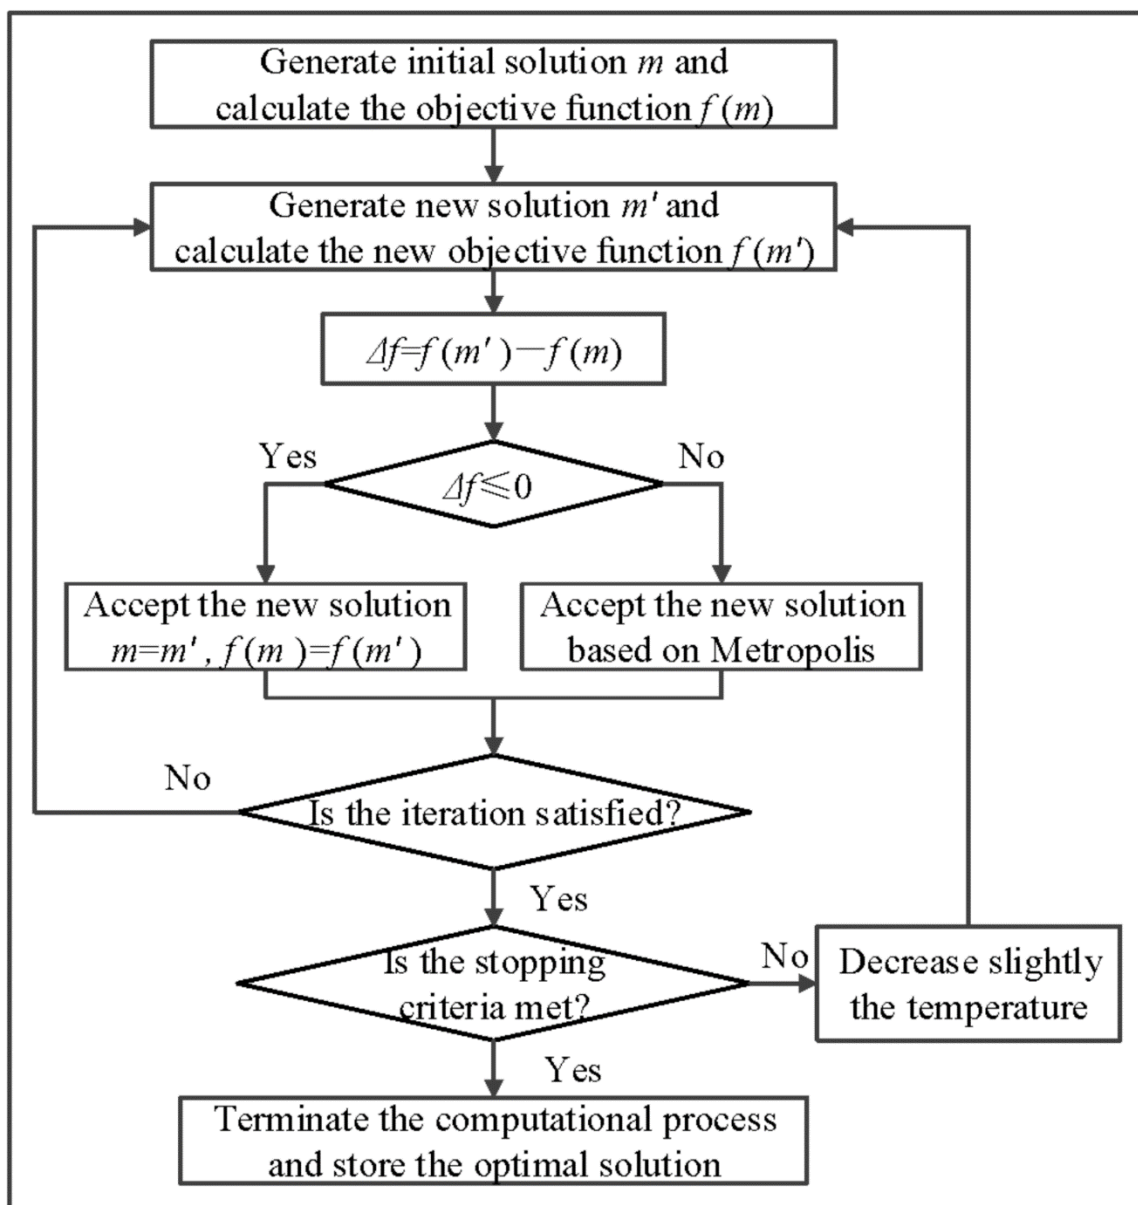
شکل ۸-۲ - خروجی پیاده سازی الگوریتم تبرید شبیه سازی<sup>۱</sup>

پارامترهای انتخاب شده در الگوریتم برابر  $\maxtemp = 1000$  و نقطه اولیه  $x = (0,0)$  می باشد، همچنین برای به روزرسانی بردار  $x$  در هر مرحله، عددی تصادفی گوسی با میانگین  $x$  قبلی و واریانس  $T$  با آن جمع کردیم. دلیل انتخاب  $\maxtemp = 1000$  در الگوریتم افزایش اطمینان در پیدا کردن مقدار بهینه است، و انتخاب نقطه اولیه به صورت دلخواه انجام شده است.

a	[44.4327,49.8459]
del	4.5748e+03
f	@(x)(x(1)^2-10*x(2)*...
f0	-75.5431
fx	5.3296
fxx	4.5801e+03
iter	100
k	1000
maxtemps	100
T	99
x	[-3.2961,3.2066]
x0	[9.7325,5.0119]
xx	[41.1366,53.0525]

شکل ۹-۲ - متغیرهای خروجی بعد از شبیه سازی

<sup>۱</sup> Simulated Annealing



شکل ۱۰-۲ - الگوریتم استفاده شده در قسمت ج

### سوال ۳

در قسمت الف با نوشتن روابط، معادله خط جدا کننده را می یابیم، در قسمت ب برای روش های بدون استفاده از کتابخانه sklearn داده های با برچسب 0 در مقابل سایر داده ها با برچسب 1 و 2 طبقه بندی شد. اما در قسمت استفاده از کتابخانه sklearn هر ۳ نوع داده را طبقه بندی کردیم. به همین دلیل دقت به دست آمده در بخش دوم کمتر است چون ۳ نوع طبقه بندی داریم.

الف:

$$\tilde{S}_1 = \begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix}, \tilde{S}_2 = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix}, \tilde{S}_3 = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$$

$$\alpha_1 \tilde{S}_1 \cdot \tilde{S}_1 + \alpha_2 \tilde{S}_2 \cdot \tilde{S}_1 + \alpha_3 \tilde{S}_3 \cdot \tilde{S}_1 = -1$$

$$\alpha_1 \tilde{S}_1 \cdot \tilde{S}_2 + \alpha_2 \tilde{S}_2 \cdot \tilde{S}_2 + \alpha_3 \tilde{S}_3 \cdot \tilde{S}_2 = 1$$

$$\alpha_1 \tilde{S}_1 \cdot \tilde{S}_3 + \alpha_2 \tilde{S}_2 \cdot \tilde{S}_3 + \alpha_3 \tilde{S}_3 \cdot \tilde{S}_3 = 1$$


$$\begin{cases} 2\alpha_1 + \alpha_2 = -1 \\ \alpha_1 + 2\alpha_2 + \alpha_3 = 1 \\ \alpha_2 + 2\alpha_3 = 1 \end{cases}$$

$$\rightarrow \alpha_1 = -1, \alpha_2 = 1, \alpha_3 = 0$$

$$\tilde{W} = \sum_i \alpha_i \cdot \tilde{S}_i = \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix} \rightarrow w = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, b = 0$$

$$y = \vec{w}x + b \rightarrow y = -x$$


پ:



شکل ۳-۱ داده های مرتبط با دسته اول به رنگ خاکستری و بقیه داده ها به رنگ سبز و خط جدا کننده SVM به رنگ سبز  
روش Stochastic Gradient Descent

```
predicted  0  1
actual
0         22  0
1          0  8
predicted  0  1
actual
0         1.0  0.0
1         0.0  1.0
Accuracy is 100.0
```

شکل ۳-۲ ماتریس آشفتگی و اطمینان و دقت آموزش روش Stochastic Gradient Descent




شکل ۳-۳ داده های مرتبط با دسته اول به رنگ خاکستری و بقیه داده ها به رنگ قرمز و خط جدا کننده SVM به رنگ سبز  
روش Gradient Descent با Armijo

```

predicted  0  1
actual
0          20  0
1           1  9
predicted   0   1
actual
0          1.00  0.0
1          0.05  0.9
Accuracy is 96.66666666666667

```

شکل ۳-۴ ماتریس آشفتگی و اطمینان و دقت آموزش روش Gradient Descent با Armijo



شکل ۳-۵- مناطق مشخص شده در طبقه بندی با استفاده از SVM

```
Confusion Matrix
[[16  0  0]
 [ 1  9  8]
 [ 0  3  8]]
Confidence Matrix
[[1.         0.         0.         ]
 [0.05555556 0.5       0.44444444]
 [0.         0.27272727 0.72727273]]
Accuracy: 81 %
```

شکل ۳-۶- ماتریس آشفتگی و اطمینان و دقت آموزش



در موارد بالا ماتریس اطمینان همان نرمالایز شده ماتریس آشفتگی می باشد و دقت با استفاده از ماتریس آشفتگی به صورت جمع مولفه های قطر اصلی تقسیم بر جمع کل درایه های ماتریس به دست می آید، همچنین از نتایج بالا میفهمیم که روش Stochastic Gradient Descent با تعداد تکرار کمتر دقت بهتری به ما می دهد و همچنین با داده های کمتری می توان از این روش برای آموزش استفاده کرد.